Дообучение Cutie для сегментации документов

Сравнение исходной и специализированной моделей

Аннотация. На 717 валидационных видео дообучение Cutie повысило J&F с 97,879 до 99,449%, а Boundary IoU — с 90,248 до 94,925%. Сравнение выполнено при одинаковой инициализации и настройках инференса.

1 Условия эксперимента

Сопоставлены исходная Cutie base-mega (baseline) и дообученная модель (finetuned) с той же архитектурой. Использованы SmartDoc2015, MIDV-2020, MIDV-500, MIDV-2019, MIDV-Holo и DLC-2021: 2836 обучающих и 717 валидационных последовательностей, всего 200 106 кадров. Связанные экземпляры и шаблоны не пересекаются между выборками. Эталонные маски получены растеризацией размеченных четырёхугольников документов.

Дообучение выполнено от исходных весов: 30 000 итераций, seed 42, learning rate $1 \cdot 10^{-5}$, batch 2, последовательности по 8 кадров, crop 480×480, 3 опорных кадра и AMP. Обрабатывается один документ без смешивания последовательностей.

Для обеих моделей использованы одинаковые кадры, начальные GT-маски и параметры инференса. Внутренний размер Cutie — 480; оценка проводится в исходном разрешении. Учтены 37 884 кадра после инициализации; начальные и предшествующие им кадры исключены. Метрики качества усредняются по кадрам видео, затем по видео датасета и поровну по шести датасетам.

2 Количественные результаты

Таблица 1. Метрики двух моделей на общей валидации. Δ = finetuned − baseline.

Метрика	Исходная	Дообученная	Δ
Область и границы			
J, % ↑	98,066	**99,145**	+1,079
DAVIS F, % ↑	97,693	**99,754**	+2,061
J&F, % ↑	97,879	**99,449**	+1,570
Boundary IoU, % ↑	90,248	**94,925**	+4,677
Временная устойчивость			
J Decay, п.п. ↓	0,5482	**0,1010**	−0,4472
F Decay, п.п. ↓	1,2421	**0,0996**	−1,1425
Boundary IoU Decay, п.п. ↓	2,6124	**0,6247**	−1,9877
Стандартное отклонение J&F, п.п. ↓	1,1160	**0,3270**	−0,7890
Среднее соседнее изменение J&F, п.п.	−0,0389	−0,0059	+0,0331
Средний модуль изменения J&F, п.п. ↓	0,4197	**0,1661**	−0,2536
Скорость обработки			
Скорость модели, FPS ↑	**39,30**	33,72	−5,57
Скорость полного прохода, FPS ↑	**16,03**	13,67	−2,36
Время модели, с ↓	**982,29**	1144,58	+162,29
Время полного прохода, с ↓	**2407,79**	2824,17	+416,38

Голубой заливкой выделены ключевые метрики J&F и Boundary IoU; полужирным — лучшие значения. Стрелки задают предпочтительное направление. Δ для строк в процентах выражена в п.п.; для остальных строк — в единицах метрики.

F использует допуск 0,8% диагонали кадра, Boundary IoU — полосу шириной 2%. Decay — среднее в начале видео минус среднее в конце. Стандартное отклонение и соседние изменения сначала вычисляются внутри видео, затем усредняются по видео и поровну по датасетам.

Знаковое соседнее изменение показывает направленный дрейф J&F; для него предпочтительное направление не задаётся. Средний модуль разности отражает амплитуду изменений между соседними кадрами.

Скорость измерена на RTX 4060 Laptop GPU с CUDA и AMP. Время и FPS включают инициализацию, но исключают загрузку весов. Полный проход включает чтение кадров, инференс и сохранение масок. Отдельный повторяемый бенчмарк скорости не выполнялся.

Дообученная модель превосходит исходную по Boundary IoU на каждом датасете; прирост составляет 3,162–6,790 п.п. Среднее снижение Boundary IoU к концу видео (Decay) уменьшается с 2,612 до 0,625 п.п.

3 Вывод и ограничения

Дообучение улучшило совпадение области и контура документа с эталонной разметкой. Эксперимент выполнен с одним seed; доверительные интервалы и качество на независимых съёмках не оценивались. Граничные метрики не измеряют непосредственно смещение углов или точность выравнивания страницы.

Воспроизводимость. Параметры заданы в config.yaml; полный парный протокол запускается командой uv run document-vos reproduce. В каталоге results/<запуск>/ формируются comparison-1/ с метриками и графиками и report-1/ с отчётом. Подробный протокол приведён в docs/REPORT.md.

Основа метода: Cheng H. K. et al. Putting the Object Back into Video Object Segmentation. CVPR, 2024.

Визуальное сравнение масок

Зелёным показаны предсказания моделей. Верхний ряд содержит область документа, нижний — увеличение отмеченного фрагмента. Примеры подобраны для иллюстрации расхождений контура и не заменяют оценку всей выборки.

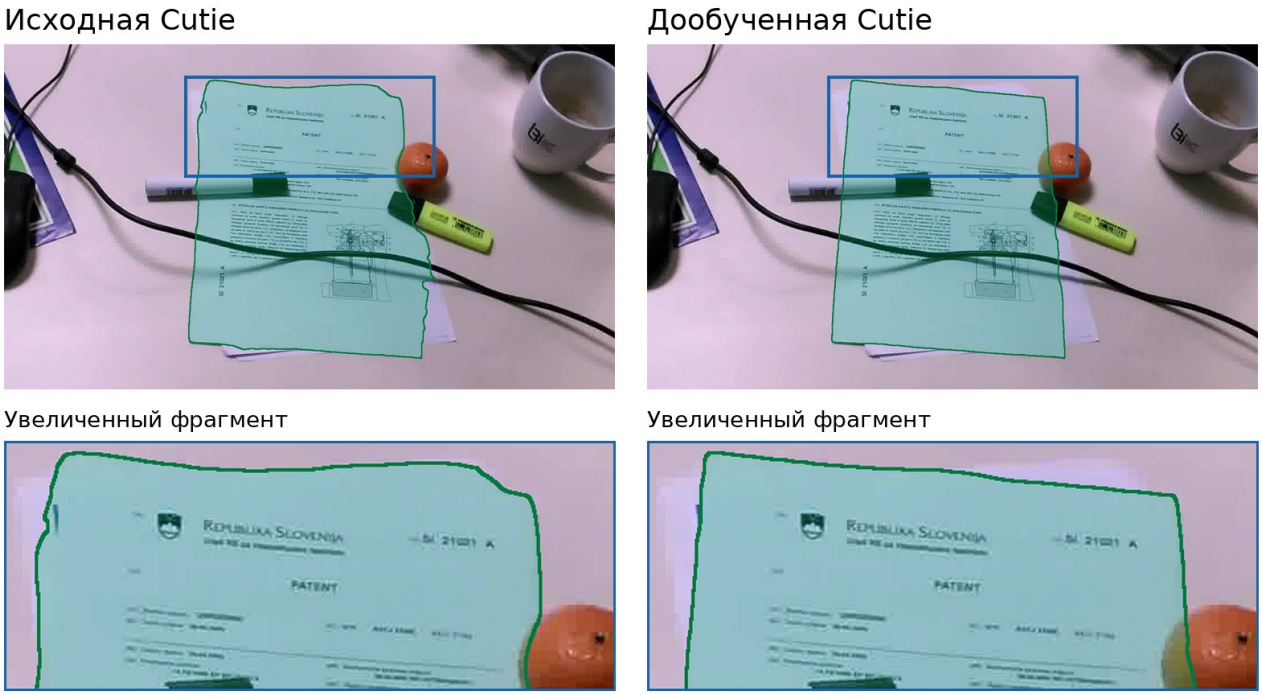


Рисунок 1. SmartDoc2015, background05/patent004, кадр 12. Boundary IoU: 77,24% у исходной и 94,99% у дообученной модели.

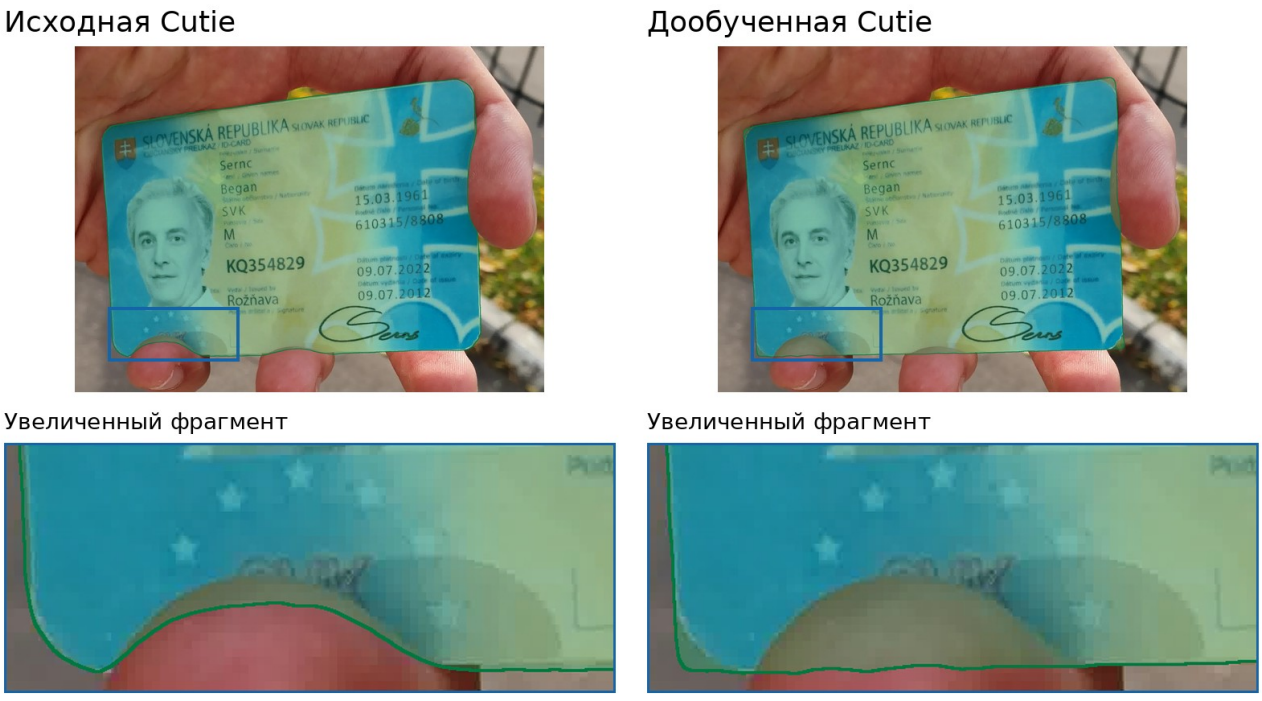


Рисунок 2. MIDV-2020, svk_id/60, кадр 000127. Boundary IoU: 77,14 и 95,30% соответственно. При перекрытии целевая разметка остаётся четырёхугольником документа.

Источники изображений: SmartDoc2015 — Burie et al., 2015, CC BY 4.0; MIDV-2020 — Bulatov et al., 2021, CC BY-SA 2.5. Лица MIDV-2020: Generated Photos.